Phân tích khả thi crawler bóng đá

https://gemini.google.com/app/fb732e66a570a90d

User prompt: Phân tích khả thi: Nhiệm vụ: - Tìm kiếm các website cung cấp dữ liệu trận đấu lịch sử, chẳng hạn như kết quả thi đấu, ngày thi đấu, giải đấu, mùa giải và tên hai đội. - Viết chương trình thu thập dữ liệu bằng Python với requests, BeautifulSoup hoặc công cụ phù hợp với cấu trúc website. - Xử lý phân trang, lỗi kết nối, dữ liệu trùng lặp và lưu dữ liệu thô thành CSV, JSON hoặc cơ sở dữ liệu. - Lưu lại URL nguồn, thời điểm thu thập và nhật ký lỗi để có thể kiểm tra nguồn gốc dữ liệu. Không chỉ lấy tỷ số cuối trận, người 1 cần xây dựng crawler thu thập nhiều loại dữ liệu: - Dữ liệu trận đấu: ngày thi đấu, đội chủ nhà, đội khách, tỷ số cuối trận. - Thống kê trận đấu: số cú sút, sút trúng đích, kiểm soát bóng, phạt góc, thẻ vàng và thẻ đỏ. - Dữ liệu đội bóng: tên đội, giải đấu, mùa giải, thông tin sân nhà. - Dữ liệu theo mùa giải: lịch thi đấu, kết quả các vòng và bảng xếp hạng. Thiết kế các crawler riêng cho từng nguồn, sau đó chuẩn hóa kết quả theo một schema chung. Nếu một nguồn không cung cấp đủ thông tin, có thể sử dụng API dữ liệu được phép truy cập để bổ sung. Độ khó tăng thêm: Phải giải quyết sự khác biệt về định dạng, tên đội và mã trận đấu giữa các nguồn. Sản phẩm bàn giao: Chương trình crawler và bộ dữ liệu trận đấu thô ban đầu.

Response: Dự án thu thập dữ liệu lịch sử bóng đá nhiều nguồn có **tính khả thi kỹ thuật cao**, nhưng độ phức tạp tập trung chủ yếu vào cơ chế chống bot (anti-bot) của các trang web thể thao và khâu chuẩn hóa thực thể (entity resolution) giữa các nguồn.

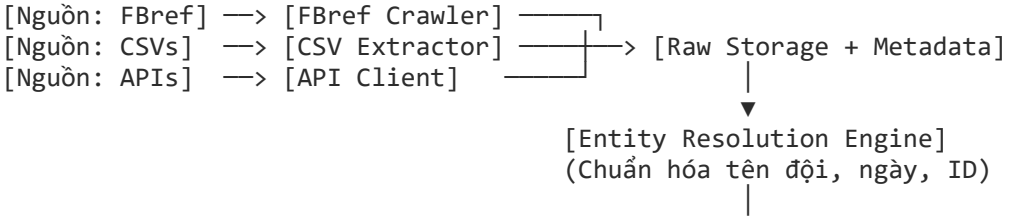
1. Đánh giá nguồn dữ liệu khả thi

Các trang web thể thao sử dụng các mô hình hiển thị dữ liệu khác nhau (Server-Side Rendering - SSR, Single Page Application - SPA, hoặc render qua WebSocket/Internal API).

Nguồn dữ liệu	Nhóm dữ liệu cung cấp	Cấu trúc kỹ thuật	Mức độ phức tạp	Rủi ro / Lưu ý
FBref	Đầy đủ: Lịch sử, BXH, sút, kiểm soát, thẻ phạt, xG, thông tin đội.	HTML tĩnh / SSR (Bảng HTML chuẩn).	Trung bình	Giới hạn tần suất nghiêm ngặt (tối đa 20 yêu cầu/phút; vi phạm sẽ bị khóa IP tạm thời 1 giờ).
Football-Data.co.uk	Tỷ số, sút, thẻ, phạt góc, lịch thi đấu nhiều mùa giải.	File CSV lưu trữ trực tiếp theo mùa.	Thấp	Cực kỳ ổn định để làm nguồn dữ liệu nền tảng (baseline), không có anti-bot.
Flashscore / Sofascore	Rất chi tiết: Thống kê trận theo thời gian thực/lịch sử, sân vận động, trọng tài.	SPA / Tải dữ liệu qua REST API nội bộ hoặc WebSocket.	Cao	Chặn Cloudflare, cấu trúc endpoint nội bộ thường xuyên thay đổi token xác thực.
Transfermarkt	Thông tin sân vận động, sức chứa, giá trị đội hình, lịch sử giải đấu.	SSR kết hợp dynamic elements.	Trung bình - Cao	Dùng Cloudflare bảo vệ; dữ liệu thống kê trong trận (sút, thẻ) không chi tiết bằng FBref.
Football-Data.org (API)	Lịch thi đấu, kết quả, BXH, đội bóng.	REST API chuẩn (JSON).	Rất thấp	Giới hạn 10 cuộc gọi/phút ở gói miễn phí; dùng làm nguồn chuẩn hóa tên đội và ID.

2. Kiến trúc hệ thống và Công nghệ đề xuất

Mô hình thiết kế hướng module (Modular Scraper Architecture) phân tách hoàn toàn giữa tầng thu thập thô, tầng làm sạch và tầng chuẩn hóa schema.



▼
[Unified Schema Database]

Ngăn xếp công nghệ (Tech Stack)

- **Thu thập (Scraping):**
  - `httpx` hoặc `curl_cffi`: Thay thế `requests` để hỗ trợ HTTP/2 và giả lập TLS fingerprint (giảm thiểu bị chặn bot).
  - `BeautifulSoup4` + `lxml`: Phân tích cú pháp HTML nhanh cho các trang SSR (FBref, Transfermarkt).
  - `playwright` (chỉ dùng dự phòng): Dành riêng cho các trang bắt buộc dựng JavaScript hoặc giải mã luồng động phức tạp.
- **Xử lý bất đồng bộ & Điều phối:** `tenacity` (retry cơ chế exponential backoff), `asyncio` hoặc `concurrent.futures`.
- **Kiểm thực & Định kiểu:** `Pydantic` để định nghĩa và xác thực schema đầu ra.
- **Chuẩn hóa thực thể (Entity Matching):** `rapidfuzz` (so khớp chuỗi mờ) kết hợp từ điển ánh xạ (alias dictionary).
- **Lưu trữ:** SQLite / PostgreSQL cho dữ liệu cấu trúc; lưu kèm bản snapshot dạng JSON Lines (`.jsonl`) cho dữ liệu thô.

3. Thiết kế Schema chuẩn hóa và Truy xuất nguồn gốc

Mỗi bản ghi phải chứa hai thành phần: **Dữ liệu thể thao** và **Siêu dữ liệu kiểm toán (Provenance Metadata)**.

Định dạng Schema mục tiêu (Pydantic Model khái niệm)

```
from datetime import datetime
from typing import Optional
from pydantic import BaseModel, Field

class MatchStats(BaseModel):
    shots_home: Optional[int] = None
    shots_away: Optional[int] = None
    shots_on_target_home: Optional[int] = None
    shots_on_target_away: Optional[int] = None
    possession_home: Optional[float] = None  # Tỷ lệ % (0.0 - 100.0)
    possession_away: Optional[float] = None
    corners_home: Optional[int] = None
    corners_away: Optional[int] = None
    yellow_cards_home: Optional[int] = None
    yellow_cards_away: Optional[int] = None
    red_cards_home: Optional[int] = None
    red_cards_away: Optional[int] = None

class UnifiedMatchRecord(BaseModel):
    # Khóa định danh hợp nhất
    match_uid: str = Field(description="Hash duy nhất: hash(date + home_id + away_id)")
    date: datetime
    season: str
    league: str

    # Đội bóng (đã chuẩn hóa tên)
    home_team: str
    away_team: str
    home_score: int
    away_score: int

    # Sân vận động & Chi tiết
    venue: Optional[str] = None
```

```
    stats: Optional[MatchStats] = None

    # Dữ liệu nguồn & Kiểm tra dấu vết (Audit Trails)
    source_name: str
    source_url: str
    crawled_at: datetime
    raw_payload_checksum: str  # SHA256 kiểm tra trùng lặp
```

4. Xử lý các thách thức kỹ thuật cốt lõi

1. Sự khác biệt về tên đội (Team Name Normalization)

- **Vấn đề:** Cùng một đội bóng nhưng xuất hiện dưới nhiều tên khác nhau: *"Man Utd"*, *"Manchester United"*, *"Manchester United FC"*, *"Man United"*.
- **Giải pháp:**
  1. Xây dựng bảng từ điển ánh xạ (`team_alias_map.json`): Ánh xạ tất cả biến thể về một mã duy nhất (ví dụ: `MAN_UTD`).
  2. Áp dụng thuật toán Levenshtein/Token Sort Ratio thông qua thư viện `rapidfuzz` cho các tên chưa có trong từ điển. Thiết lập ngưỡng tin cậy (similarity score $\geq 85\%$). Nếu dưới ngưỡng, ghi vào hàng đợi xem xét thủ công (manual review queue).

2. Sự khác biệt về mã trận đấu (Match ID Resolution)

- **Vấn đề:** FBref, Flashscore và các API dùng ID hoàn toàn khác nhau.
- **Giải pháp:** Tạo **Khóa tổng hợp (Composite Key)** độc lập với mã của nguồn:

  $$\text{Match UID} = \text{SHA256}(\text{ISO_Date} + \text{"_"} + \text{Sorted}(\text{Standard_Home_ID}, \text{Standard_Away_ID}))$$

  Khóa này đảm bảo mọi nguồn khi thu thập cùng một trận đấu vào cùng một ngày đều quy tụ về một định danh duy nhất.

3. Phân trang và phát hiện trùng lặp (Deduplication)

- Phân tầng thu thập: `Index Crawler` (lấy danh sách URL theo mùa giải/vòng đấu) tách biệt với `Detail Crawler` (lấy thống kê chi tiết trận).
- Trước khi gửi request tải chi tiết trận, kiểm tra xem `source_url` hoặc `match_uid` đã tồn tại trong cơ sở dữ liệu hay chưa. Nếu đã có, bỏ qua để tiết kiệm băng thông và tránh kích hoạt rate limit.

4. Quản lý lỗi và Ghi log

- Triển khai bộ xử lý `RotatingFileHandler` chia làm hai file nhật ký: `crawler_activity.log` (ghi nhận tiến độ, URL, mã phản hồi HTTP) và `crawler_errors.log` (ghi chi tiết lỗi ngoại lệ, URL thất bại, traceback).
- Bảng lưu trữ phụ `failed_jobs`: Lưu các URL gặp mã lỗi 4xx/5xx hoặc lỗi parse HTML kèm số lần thử lại (retry count) để chạy tác vụ quét bù (backfill).

5. Kế hoạch triển khai và Bàn giao

Lộ trình thực hiện

1. **Giai đoạn 1: Khởi tạo & Thu thập baseline**
   - Xây dựng module lấy dữ liệu lịch sử từ `Football-Data.co.uk` (lấy toàn bộ kết quả, thẻ phạt, phạt góc nhiều mùa giải về định dạng chuẩn).
   - Tạo cơ chế ghi log và bảng kiểm tra nguồn gốc dữ liệu.
2. **Giai đoạn 2: Crawler chi tiết (FBref)**

- Viết module bóc tách bảng thống kê chuyên sâu từ FBref bằng `BeautifulSoup`.
- Cài đặt cơ chế kiểm soát tốc độ (Rate Limiter: trễ 3.5 – 5 giây ngẫu nhiên giữa các request) để duy trì dưới ngưỡng 20 req/phút.

3. **Giai đoạn 3: Chuẩn hóa và Khử trùng lặp**
   - Xây dựng bộ máy ánh xạ tên đội (Fuzzy Matching + Mapping table).
   - Hợp nhất dữ liệu trận đấu và thông tin sân vận động từ nguồn bổ trợ.
4. **Giai đoạn 4: Đóng gói và Bàn giao**
   - Xuất bộ dữ liệu thô ban đầu (CSV/JSONL có kèm URL, timestamp).
   - Đóng gói mã nguồn với file cấu hình, tài liệu hướng dẫn chạy (README) và file yêu cầu môi trường (`requirements.txt`).

User prompt: Tôi muốn có nhiều thông tin nhất có thể

Response: Dưới đây là đặc tả kỹ thuật toàn diện, kiến trúc mã nguồn và quy trình xử lý chi tiết từ đầu đến cuối cho hệ thống thu thập, chuẩn hóa dữ liệu bóng đá đa nguồn.

1. Cấu trúc thư mục dự án (Project Layout)

```
football_pipeline/
├── config/
│   ├── settings.yaml            # Cấu hình headers, proxies, rate limits, DB URI
│   └── team_aliases.json        # Từ điển chuẩn hóa tên đội (Lookup dictionary)
├── data/
│   ├── raw/                     # Dữ liệu thô lưu theo định dạng JSONL/CSV theo ngày
│   └── logs/                    # File log hoạt động và log lỗi
├── db/
│   ├── schema.sql               # File DDL khởi tạo cơ sở dữ liệu
│   └── session.py               # Kết nối DB và engine quản lý phiên
├── crawlers/
│   ├── base.py                  # Lớp BaseCrawler (Rate limit, retry, provenance log)
│   ├── fbref_crawler.py         # Module bóc tách FBref (HTML/SSR)
│   ├── footballdata_crawler.py  # Module lấy dữ liệu Football-Data.co.uk (CSV)
│   └── api_crawler.py           # Module lấy dữ liệu Football-Data.org (REST API)
├── pipeline/
│   ├── models.py                # Schema định dạng chuẩn bằng Pydantic
│   ├── normalizer.py            # Giải thuật chuẩn hóa tên đội và tạo Match UID
│   └── storage.py               # Lưu trữ dữ liệu thô và nạp vào DB
├── requirements.txt
└── main.py                      # File điều phối luồng thu thập toàn cục
```

2. Thiết kế Cơ sở dữ liệu và Schema chuẩn hóa

2.1. Cấu trúc Bảng Cơ sở dữ liệu (PostgreSQL / SQLite DDL)

Hệ thống phân tách bảng dữ liệu chuyên môn, bảng siêu dữ liệu nguồn và bảng từ điển ánh xạ:

```
-- Bảng nhật ký nguồn thu thập (Audit Trails)
CREATE TABLE IF NOT EXISTS crawl_audits (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    source_name VARCHAR(50) NOT NULL,
    source_url TEXT NOT NULL,
    status_code INTEGER,
    raw_payload_checksum VARCHAR(64) NOT NULL,
    created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
    error_message TEXT
);
```

```
-- Bảng chuẩn hóa định danh đội bóng
CREATE TABLE IF NOT EXISTS teams (
    team_id VARCHAR(50) PRIMARY KEY,      -- Mã quy chuẩn: e.g. "ARSENAL"
    canonical_name VARCHAR(100) NOT NULL, -- Tên hiển thị chuẩn: "Arsenal FC"
    country VARCHAR(50),
    stadium_name VARCHAR(100),
    stadium_capacity INTEGER
);

-- Bảng ánh xạ bí danh tên đội từ các nguồn khác nhau
CREATE TABLE IF NOT EXISTS team_aliases (
    alias VARCHAR(100) PRIMARY KEY,       -- Tên xuất hiện trên web: e.g. "Arsenal London"
    team_id VARCHAR(50) NOT NULL,
    source_name VARCHAR(50) NOT NULL,
    FOREIGN KEY (team_id) REFERENCES teams(team_id)
);

-- Bảng thông tin trận đấu hợp nhất
CREATE TABLE IF NOT EXISTS matches (
    match_uid VARCHAR(64) PRIMARY KEY,    -- SHA256(date + sorted(home_id, away_id))
    league VARCHAR(50) NOT NULL,
    season VARCHAR(20) NOT NULL,
    match_date DATE NOT NULL,
    home_team_id VARCHAR(50) NOT NULL,
    away_team_id VARCHAR(50) NOT NULL,
    home_score INTEGER NOT NULL,
    away_score INTEGER NOT NULL,
    source_audit_id INTEGER,
    FOREIGN KEY (home_team_id) REFERENCES teams(team_id),
    FOREIGN KEY (away_team_id) REFERENCES teams(team_id),
    FOREIGN KEY (source_audit_id) REFERENCES crawl_audits(id)
);

-- Bảng thống kê chi tiết trận đấu
CREATE TABLE IF NOT EXISTS match_stats (
    match_uid VARCHAR(64) PRIMARY KEY,
    shots_home INTEGER,
    shots_away INTEGER,
    shots_on_target_home INTEGER,
    shots_on_target_away INTEGER,
    possession_home REAL,
    possession_away REAL,
    corners_home INTEGER,
    corners_away INTEGER,
    yellow_cards_home INTEGER,
    yellow_cards_away INTEGER,
    red_cards_home INTEGER,
    red_cards
```

User prompt: Chưa bàn đến cấu trúc nghiệp vụ. Tôi muốn có nhiều thông tin nhất có thể, đa dạng các thuộc tính từ đội bóng, cầu thủ, mùa giải, v.v.v.

Response: Hệ thống thuộc tính toàn diện trong dữ liệu bóng đá được phân tách thành 7 nhóm thực thể chính, bao quát từ dữ liệu định danh cơ bản đến các chỉ số thống kê sự kiện và đo lường nâng cao:

1. Thực thể Đội bóng (Club / Team Attributes)

Nhóm thuộc tính	Thuộc tính cụ thể	Ý nghĩa / Đơn vị
Định danh & Hồ sơ	`team_id`, `name`, `official_name`, `short_name`, `three_letter_code` (TLA)	Tên đầy đủ, tên thương mại, mã viết tắt 3 ký tự (e.g., ARS, MCI).
	`founded_year`, `country`, `city`, `club_colors`, `logo_url`, `website`	Năm thành lập, xuất xứ địa lý, màu áo truyền thống.
Sân vận động & Cơ sở	`stadium_name`, `stadium_capacity`, `pitch_surface`, `pitch_dimensions`	Tên sân nhà, sức chứa, mặt cỏ (tự nhiên/nhân tạo/lai), kích thước (m).
	`construction_year`, `geo_coordinates` (lat, lon)	Năm khánh thành, tọa độ địa lý sân.
Tài chính & Quản trị	`owner`, `chairman`, `market_value_total`, `wage_bill_annual`	Chủ sở hữu, tổng giá trị đội hình ước tính (€/£), tổng quỹ lương.
Đặc tính chiến thuật	`preferred_formation`, `avg_squad_age`, `foreign_players_ratio`	Sơ đồ ưa thích, tuổi trung bình đội hình, tỷ lệ cầu thủ ngoại binh (%).

2. Thực thể Cầu thủ (Player Attributes)

- **Nhân khẩu học & Thể chất:**
  - `player_id`, `full_name`, `birth_name`, `date_of_birth`, `age`.
  - `citizenship_primary`, `citizenship_secondary` (quốc tịch kép).
  - `height_cm`, `weight_kg`.
  - `preferred_foot` (chân thuận: trái, phải, cả hai).
  - `primary_position` (vị trí chính: GK, CB, LB, RB, DM, CM, AM, LW, RW, ST).
  - `secondary_positions` (danh sách các vị trí phụ có thể thi đấu).
- **Hợp đồng & Giá trị thị trường:**
  - `current_club_id`, `shirt_number`, `joined_date`, `contract_expires`.
  - `market_value_current`, `highest_market_value_historic`, `weekly_wage`.
  - `release_clause_value` (phí phá vỡ hợp đồng), `agent_name` (người đại diện).
- **Hồ sơ y tế & Kỷ luật:**
  - `injury_history`: Danh sách chấn thương (loại tổn thương, ngày bắt đầu, ngày hồi phục, số ngày nghỉ, số trận bỏ lỡ).
  - `suspension_status`: Treo giò (do tích lũy thẻ hoặc thẻ đỏ, số trận còn lại).

3. Bối cảnh & Điều kiện Trận đấu (Match Metadata & Environment)

- **Thông tin tổ chức:**
  - `match_id`, `competition_id`, `season_id`, `matchday` / `gameweek` (vòng đấu), `round_type` (vòng bảng, tứ kết, playoff).
  - `kickoff_datetime_utc`, `kickoff_datetime_local`, `status` (Finished, Postponed, Cancelled, Abandoned).
- **Địa điểm & Môi trường thi đấu:**
  - `venue_id`, `attendance` (số lượng khán giả thực tế), `stadium_fill_rate` (% lấp đầy).

- `weather_condition` (Clear, Rain, Snow, Fog), `temperature_celsius`, `humidity_percent`, `wind_speed_kmh`.

- **Tổ trọng tài:**
  - `referee_id`, `referee_name`, `assistant_referees`, `fourth_official`, `var_referee`.
  - `historic_referee_strictness` (trung bình số thẻ vàng, thẻ đỏ, penalty rút ra mỗi trận trong sự nghiệp).
- **Đội hình xuất phát & Huấn luyện viên:**
  - `home_manager_id`, `away_manager_id`.
  - `home_formation`, `away_formation` (ví dụ: 4-3-3, 3-4-2-1).
  - `lineup_starting_xi` (danh sách 11 cầu thủ đá chính kèm tọa độ vị trí trên sân `x, y`).
  - `lineup_bench` (danh sách cầu thủ dự bị).

4. Thống kê Diễn biến & Trận đấu (Match-Level Performance & Event Data)

4.1. Kết quả & Diễn biến thời gian

- **Tỷ số:** Tỷ số hiệp 1 (`HT`), hiệp 2 (`FT`), hiệp phụ (`ET`), loạt sút luân lưu (`Penalties`).
- **Timeline sự kiện:**
  - Bàn thắng: Phút ghi bàn, người ghi bàn, người kiến tạo, dạng bàn thắng (bóng sống, phạt góc, đá phạt trực tiếp, penalty, phản lưới nhà - `own_goal`).
  - Thay người: Phút thay đổi, cầu thủ ra, cầu thủ vào, lý do (chiến thuật / chấn thương).
  - Kỷ luật: Thẻ vàng, thẻ vàng thứ hai thành thẻ đỏ, thẻ đỏ trực tiếp, phút phạt thẻ.

4.2. Thống kê kỹ thuật cơ bản (Đội chủ nhà vs Đội khách)

- **Tấn công:** Tổng cú sút (`Total Shots`), sút trúng đích (`Shots on Target`), sút ra ngoài (`Shots off Target`), sút bị chặn (`Blocked Shots`), bóng trúng xà/cột (`Hit Woodwork`).
- **Kiểm soát & Phân phối:** Tỷ lệ kiểm soát bóng (`Possession %`), tổng số đường chuyền (`Total Passes`), đường chuyền chính xác, tỷ lệ chuyền chính xác (%), chuyền thành công ở 1/3 sân đối phương (`Final Third Passes`), tạt bóng (`Crosses` - tổng/chính xác), phạt góc (`Corners`), việt vị (`Offsides`).
- **Phòng ngự & Tranh chấp:** Tắc bóng (`Tackles` - tổng/thành công), đánh chặn (`Interceptions`), cản phá (`Clearances`), cứu thua trên vạch vôi, tranh chấp tay đôi (`Ground Duels` - thắng/thua), tranh chấp trên không (`Aerial Duels` - thắng/thua).
- **Thủ môn:** Số lần cứu thua (`Saves`), bắt dính bóng, đấm bóng giải nguy (`Punches`), cứu thua trong vùng cấm (`Saves from Inside Box`), cản phá penalty.

4.3. Chỉ số phân tích chuyên sâu (Advanced & Expected Metrics)

- **Mô hình bàn thắng & kiến tạo kỳ vọng:**
  - `xG` (Expected Goals): Tổng chất lượng cơ hội tạo ra.
  - `npxG` (Non-Penalty Expected Goals): xG không tính phạt đền.
  - `xGA` (Expected Goals Against): Bàn thua kỳ vọng.
  - `xA` (Expected Assists) / `xAG` (Expected Assisted Goals).
  - `PSxG` (Post-Shot Expected Goals): xG tính theo quỹ đạo bóng sau cú sút (dùng để đo hiệu quả cản phá của thủ môn).

- **Mô hình luân chuyển bóng & Áp lực:**
  - `Progressive Passes` (Đường chuyền tịnh tiến: đưa bóng về phía khung thành đối phương ≥ 10 yards hoặc vào vòng cấm).
  - `Progressive Carries` (Dẫn bóng tịnh tiến).
  - `PPDA` (Passes Allowed Per Defensive Action): Số đường chuyền cho phép đối phương thực hiện trước khi có hành động phòng ngự (đo lường cường độ pressing).
  - `Field Tilt`: Tỷ lệ kiểm soát bóng tính riêng ở 1/3 sân cuối cùng của đối phương.
  - `SCA` (Shot-Creating Actions) & `GCA` (Goal-Creating Actions): 2 hành động tấn công dẫn trực tiếp tới cú sút hoặc bàn thắng.

5. Thống kê Cá nhân Cầu thủ trong Trận (Player Match-Level Stats)

- `minutes_played` (Số phút có mặt trên sân).
- `rating` (Điểm số trận đấu từ các trang thống kê: Sofascore, WhoScored, FotMob).
- `touches` (Tổng số lần chạm bóng), `touches_in_opposition_box` (chạm bóng trong vòng cấm đối phương).
- `dribbles_attempted`, `dribbles_succeeded` (Rê bóng qua người).
- `dispossessed` (Số lần bị đối phương cướp bóng), `bad_control` (Khống chế bóng hỏng).
- `key_passes` (Đường chuyền mở ra cú sút cho đồng đội).
- `big_chances_created` (Tạo cơ hội ghi bàn mười mươi), `big_chances_missed` (Bỏ lỡ cơ hội mười mươi).
- `shot_map_events`: Tọa độ `x, y` của từng cú sút, bộ phận cơ thể thực hiện (chân trái, chân phải, đánh đầu), cự ly (mét), góc sút.

6. Mùa giải & Giải đấu (League & Season Data)

- **Cấu trúc giải:**
  - `league_id`, `league_tier` (Hạng 1, Hạng 2,...), `continent` / `confederation` (UEFA, CONMEBOL,...).
  - `season_year` (ví dụ: `2024/2025`, `2025/2026`).
  - `promotion_slots`, `relegation_slots`, `champions_league_slots`, `europa_league_slots`.
- **Bảng xếp hạng tổng hợp (Standings):**
  - `rank`, `points`, `matches_played`, `wins`, `draws`, `losses`.
  - `goals_for` (GF), `goals_against` (GA), `goal_difference` (GD).
  - `home_record` (Thắng - Hòa - Thua - Bàn thắng/bại khi đá sân nhà).
  - `away_record` (Thắng - Hòa - Thua - Bàn thắng/bại khi đá sân khách).
  - `form_guide` (Kết quả 5 trận gần nhất, e.g., `W-W-D-L-W`).
  - `head_to_head` (Thành tích đối đầu giữa các đội bằng điểm).

7. Thị trường Cá cược & Tỷ lệ Cược (Betting & Market Odds)

Dữ liệu này phản ánh xác suất thực tế và kỳ vọng thị trường tại từng thời điểm:

- **Thị trường 1X2 (Match Result):**
  - Tỷ lệ mở kèo (`Opening Odds`) và Tỷ lệ đóng kèo trước giờ bóng lăn (`Closing Odds`) từ các nhà cái (Bet365, Pinnacle, William Hill, Betfair Exchange).

- Các giá trị: `home_win_odds`, `draw_odds`, `away_win_odds`.

- **Thị trường Kèo Châu Á (Asian Handicap):**
  - `handicap_line` (Mức chấp: ví dụ -0.5, -1.0, -1.25).
  - `handicap_home_odds`, `handicap_away_odds`.
- **Thị trường Tài/Xỉu (Over/Under):**
  - `totals_line` (Mốc bàn thắng: 1.5, 2.5, 3.5).
  - `over_odds`, `under_odds`.
- **Thị trường Phụ:**
  - `both_teams_to_score` (BTTS - Có / Không).
  - `half_time_odds` (Tỷ lệ cược riêng cho hiệp 1).

User prompt: Phân tích các nguồn dữ liệu: Tùy từng nguồn xem thuộc tính nào có thuộc tính nào không

Response: Dưới đây là bảng đối chiếu chi tiết mức độ sẵn có của các nhóm thuộc tính trên 6 nguồn dữ liệu phổ biến nhất hiện nay, kèm phân tích sâu về thế mạnh và lỗ hổng thuộc tính của từng nguồn.

Bảng ma trận thuộc tính theo nguồn dữ liệu

Nhóm thuộc tính	FBref	Transfermarkt	Sofascore / WhoScored	Football-Data.co.uk	Understat	Football-Data.org (API)
1. Đội bóng & Sân bãi (Sức chứa, mặt cỏ, năm thành lập)	Cơ bản	**Rất chi tiết**	Cơ bản	Không	Không	Cơ bản
2. Tài chính & Giá trị (Lương, chuyển nhượng, định giá)	Quỹ lương	**Rất chi tiết**	Không	Không	Không	Không
3. Hồ sơ Cầu thủ (Thể chất, chân thuận, vị trí, quốc tịch)	Đầy đủ	**Rất chi tiết**	Đầy đủ	Không	Cơ bản	Cơ bản
4. Chấn thương & Hợp đồng (Thời hạn, lịch sử chấn thương)	Không	**Rất chi tiết**	Đang chấn thương	Không	Không	Thời hạn HĐ
5. Bối cảnh trận (Trọng tài, khán giả, thời tiết, SVĐ)	Đầy đủ	Sân, khán giả, trọng tài	Đầy đủ + Thời tiết	Không	Không	Trọng tài
6. Đội hình & Chiến thuật (Sơ đồ, 11 chính thức, dự bị)	Đầy đủ	Đầy đủ	**Đầy đủ + Tọa độ sơ đồ**	Không	Đội hình cơ bản	Đầy đủ (gói trả phí)
7. Thống kê trận cơ bản (Sút, sút trúng đích, thẻ, góc)	Đầy đủ	Tỷ số, bàn thắng, thẻ	**Đầy đủ**	**Đầy đủ**	Chỉ có sút/bàn	Chỉ tỷ số (Free)
8. Chỉ số nâng cao (xG, xA, PPDA, Progressive Passes)	**Rất chi tiết**	Không	xG, xA cơ bản	Không	**Chi tiết xG/xA**	Không
9. Cá nhân trong trận (Rating, chạm	**Bảng số liệu**	Phút, bàn, kiến tạo	**Rating + Heatmap**	Không	xG từng cú sút	Không

Nhóm thuộc tính	FBref	Transfermarkt	Sofascore / WhoScored	Football-Data.co.uk	Understat	Football-Data.org (API)
bóng, rê bóng, tắc bóng)						
10. Tọa độ cú sút (Shot map x, y, góc sút, cự ly)	Không	Không	**Có (x, y)**	Không	**Có (x, y)**	Không
11. Thị trường cá cược (Kèo 1X2, Asian Handicap, O/U)	Không	Không	1X2 cơ bản	**Rất chi tiết (Mở/Đóng)**	Không	Không

Phân tích chi tiết từng nguồn dữ liệu

1. FBref (Đối tác dữ liệu Opta)

Nguồn dữ liệu dạng bảng phân tích sâu toàn diện nhất về mặt chuyên môn và diễn biến chiến thuật.

- **Thuộc tính có sẵn:**
  - **Chỉ số nâng cao toàn diện:** xG, $npxG$ (non-penalty xG), xA, xAG, $PSxG$ (xG sau cú sút tính cho thủ môn), SCA (Shot-Creating Actions), GCA (Goal-Creating Actions).
  - **Luân chuyển bóng & Áp lực:** $PPDA$, đường chuyền tịnh tiến (*Progressive Passes*), dẫn bóng tịnh tiến (*Progressive Carries*), số lần gây áp lực (*Pressures* theo từng 1/3 sân).
  - **Chi tiết cá nhân trong trận:** Bảng ma trận đầy đủ cho từng cầu thủ (số lần tắc bóng, đánh chặn, cắt bóng, tỷ lệ chuyền theo cự ly ngắn/trung bình/dài).
  - **Bối cảnh:** Tên trọng tài, số lượng khán giả, sân thi đấu, lịch thi đấu nhiều mùa giải về trước.
  - **Tài chính:** Dữ liệu quỹ lương và mức lương tuần của cầu thủ (hợp tác từ nguồn Capology).
- **Thuộc tính khuyết thiếu:**
  - **Dữ liệu tọa độ:** Không cung cấp tọa độ x, y của các cú sút hoặc bản đồ nhiệt (*Heatmap*) vị trí di chuyển của cầu thủ.
  - **Tỷ lệ cược:** Hoàn toàn không có dữ liệu kèo nhà cái.
  - **Hồ sơ hợp đồng & chấn thương:** Không lưu vết chi tiết tiền sử bệnh án, các ca chấn thương trong quá khứ hoặc điều khoản giải phóng hợp đồng.

2. Transfermarkt

Nguồn dữ liệu số một về thuộc tính hồ sơ, pháp lý, tài chính và cơ sở hạ tầng.

- **Thuộc tính có sẵn:**
  - **Định giá & Tài chính:** Giá trị thị trường lịch sử của cầu thủ qua từng mốc thời gian, phí chuyển nhượng chính thức/ước tính, điều khoản mua lại, đại diện cầu thủ (*Agents*).
  - **Hồ sơ y tế:** Danh mục toàn bộ các ca chấn thương trong sự nghiệp (loại chấn thương, số ngày phải nghỉ, số trận đấu bỏ lỡ cho cả CLB lẫn đội tuyển quốc gia).
  - **Cơ sở vật chất:** Tên sân vận động, năm xây dựng, chi phí xây dựng, kích thước mặt sân, loại mặt cỏ (tự nhiên, cỏ nhân tạo, cỏ lai *hybrid*), sức chứa thực tế và sức chứa quy chuẩn quốc tế.
  - **Ban huấn luyện & Lịch sử:** Thời hạn hợp đồng của ban huấn luyện, chủ tịch CLB, các đời HLV trưởng cùng sơ đồ chiến thuật ưa thích.
- **Thuộc tính khuyết thiếu:**

- **Thống kê kỹ thuật trận đấu:** Không có dữ liệu sút bóng, sút trúng đích, kiểm soát bóng, số đường chuyền, phạt góc (chỉ ghi nhận tỷ số, cầu thủ ghi bàn, thẻ phạt và thay người).
- **Chỉ số nâng cao:** Hoàn toàn không có xG, xA hay bất kỳ chỉ số định lượng nào.
- **Tỷ lệ cược:** Không cung cấp.

3. Sofascore / WhoScored

Nguồn dữ liệu tối ưu cho dữ liệu sự kiện chi tiết (Event Data), dữ liệu không gian và đánh giá phong độ.

- **Thuộc tính có sẵn:**
  - **Dữ liệu không gian (x, y):** Bản đồ nhiệt (*Heatmap*) của từng cầu thủ, tọa độ chính xác vị trí ra chân của các cú sút kèm điểm đến của bóng trên khung thành.
  - **Chỉ số hiệu suất tức thời:** Điểm số đánh giá cầu thủ (*Player Match Rating*) tính bằng thuật toán trực tiếp sau mỗi hành động trên sân.
  - **Chi tiết đối kháng cá nhân:** Tỷ lệ thắng tranh chấp tay đôi dưới đất (*Ground Duels*), không chiến (*Aerial Duels*), số lần qua người thành công, số lần để mất bóng (*Possession Lost*).
  - **Môi trường thi đấu:** Thời tiết tại thời điểm đá (nhiệt độ, mưa/nắng, độ ẩm), tình trạng mặt sân.
- **Thuộc tính khuyết thiếu:**
  - **Lịch sử dữ liệu dài hạn dạng bảng:** Dữ liệu được tải động (dynamic payload qua API nội bộ), rất khó bóc tách hàng loạt cho 10-20 mùa giải trước như các trang HTML tĩnh.
  - **Thông tin tài chính sâu:** Không có chi tiết quỹ lương, hợp đồng hay tiền sử chấn thương nhiều năm trước.

4. Football-Data.co.uk

Nguồn dữ liệu dạng tệp lưu trữ trực tiếp, tập trung chuyên biệt vào tỷ số và thị trường cá cược.

- **Thuộc tính có sẵn:**
  - **Tỷ lệ cược lịch sử đồ sộ:** Tỷ lệ kèo 1X2 (Chủ - Hòa - Khách), Kèo Châu Á (*Asian Handicap*), Tài/Xỉu (*Over/Under*) tại thời điểm mở kèo (*Opening*) và sát giờ thi đấu (*Closing*) từ hàng chục nhà cái (Bet365, Pinnacle, William Hill, Ladbrokes, Betfair...).
  - **Thống kê trận cơ bản:** Bàn thắng (hiệp 1 và cả trận), tổng số cú sút, sút trúng đích, phạt góc, số lỗi vi phạm (*Fouls*), thẻ vàng, thẻ đỏ.
  - **Dễ thu thập:** Tải trực tiếp qua file CSV tĩnh theo từng mùa giải từ 1993 đến nay.
- **Thuộc tính khuyết thiếu:**
  - **Cầu thủ:** Hoàn toàn không có tên cầu thủ, không có đội hình ra sân, không có người ghi bàn hay kiến tạo.
  - **Chỉ số kiểm soát & nâng cao:** Không có thời lượng kiểm soát bóng (%), không có xG, không có số đường chuyền.
  - **Thông tin sân bãi & trọng tài:** Không có dữ liệu thời tiết, sức chứa hay tổ trọng tài (một số mùa gần đây có tên trọng tài chính nhưng không có dữ liệu trợ lý hay VAR).

5. Understat

Nguồn dữ liệu chuyên sâu về giải thuật xG và tọa độ dứt điểm cho các giải vô địch quốc gia hàng đầu châu Âu.

- **Thuộc tính có sẵn:**

- **Dữ liệu cú sút có cấu trúc:** Tọa độ chính xác (x, y), giá trị xG của từng pha dứt điểm, loại tình huống (bóng sống, phản công, đá phạt trực tiếp, phạt góc, penalty), bộ phận dứt điểm (chân trái, chân phải, đánh đầu).
- **Chỉ số liên kết:** $xGChain$ (chuỗi phối hợp dẫn đến cú sút có cầu thủ tham gia), $xGBuildup$ (đóng góp kiểm soát bóng trước đường kiến tạo).

- **Thuộc tính khuyết thiếu:**
  - **Phạm vi giải đấu:** Chỉ theo dõi 6 giải đấu lớn (Ngoại hạng Anh, La Liga, Serie A, Bundesliga, Ligue 1, Giải Ngoại hạng Nga) từ năm 2014 trở lại đây; không có cúp châu Âu hay các giải hạng dưới.
  - **Hành động phòng ngự & kiểm soát bóng:** Không theo dõi số lần tắc bóng, đánh chặn, thẻ phạt, việt vị, số quả phạt góc.
  - **Thông tin ngoài sân cỏ:** Không có dữ liệu chuyển nhượng, tài chính, hợp đồng, sân vận động, tỷ lệ cược.

6. Football-Data.org / API Thể thao chuẩn hóa

Nguồn dữ liệu API RESTful có cấu trúc định danh chuẩn, phục vụ xây dựng khung sườn hệ thống.

- **Thuộc tính có sẵn:**
  - **Mã định danh duy nhất (ID System):** Cung cấp hệ thống ID thống nhất cho mùa giải, giải đấu, đội bóng, cầu thủ và trận đấu, giúp giải quyết triệt để bài toán đồng bộ tên gọi giữa các nguồn cào HTML.
  - **Lịch thi đấu & Kết quả:** Cập nhật liên tục trạng thái trận đấu (chưa đá, hoãn, đang đá, đã kết thúc), tỷ số theo thời gian thực.
  - **Bảng xếp hạng chuẩn:** Điểm số, hiệu số, hệ số đối đầu trực tiếp, chuỗi phong độ 5 trận gần nhất.
- **Thuộc tính khuyết thiếu:**
  - **Độ sâu thống kê (Gói miễn phí):** Không cung cấp các chỉ số sút, phạt góc, kiểm soát bóng, hay xG.
  - **Dữ liệu lịch sử:** Gói miễn phí bị giới hạn số mùa giải truy cập (thường chỉ cho phép 1-2 mùa gần nhất) và giới hạn tần suất gọi API (10 calls/phút).

Chiến lược kết hợp nguồn dữ liệu để đạt tập thuộc tính tối đa

Để có được bộ dữ liệu đầy đủ nhất mà không bị trùng lặp công sức thu thập:

1. **Khung sườn định danh & Lịch thi đấu:** Dùng **Football-Data.org API** hoặc bảng CSV của **Football-Data.co.uk** để lấy danh sách trận, kết quả cơ bản và toàn bộ tỷ lệ cược lịch sử.
2. **Thống kê chuyên sâu, đội hình & xG:** Dùng crawler bóc tách **FBref** để lấy bảng dữ liệu trận đấu, hành vi phòng ngự/tấn công và chỉ số nâng cao của từng cầu thủ.
3. **Hồ sơ thực thể, hợp đồng & sân bãi:** Dùng crawler bóc tách **Transfermarkt** một lần định kỳ (theo tháng hoặc theo kỳ chuyển nhượng) để thu thập thông tin sân vận động, giá trị cầu thủ, tiền sử chấn thương và hợp đồng.
4. **Dữ liệu tọa độ không gian (nếu cần mô hình hóa x, y):** Bổ sung crawler từ **Understat** hoặc endpoint API nội bộ của **Sofascore** để lấy riêng bảng dữ liệu tọa độ dứt điểm (*Shot Coordinates*).
